

---

# A Comparative Study of DnCNN and Traditional Filters for Multi-Type Image Noise Removal

---

陳禹豪  
Ming Chuan University  
Taoyuan  
1160801@mcu.edu.tw

## Abstract

本研究探討深度學習模型 DnCNN 在不同雜訊類型下的影像降噪能力，並與傳統濾波方法（中值、高斯、低通）進行系統性比較。相較於傳統濾波器在去除特定雜訊時的局限性，DnCNN 透過深層殘差學習架構，以端到端方式直接預測噪聲，具備理論上的泛化能力與細節保留潛力。在實驗設計上，本研究以 BSD 資料集為訓練資料，TID2013 為測試集，並人工添加三類常見雜訊（Gaussian、Salt-and-Pepper、Random）以進行測試。模型訓練時，特別設計了動態雜訊比例策略與結合 Charbonnier Loss 與 MSE 的混合損失函數，提升模型對複合雜訊的適應性。從實驗結果可見，DnCNN 在高斯雜訊與隨機雜訊下的表現明顯優於傳統方法，在 PSNR、MSE 與 SSIM 三項指標皆居冠。然而，在椒鹽雜訊場景中，傳統的中值濾波器於 SSIM 與 PSNR 指標上表現更佳。整體而言，DnCNN 雖無法在所有場景中完全勝出，但在平均表現上依然優於各項傳統方法，顯示其強大的整體降噪能力與穩定性。

**Keywords** Image Denoising · DnCNN · Gaussian Noise · Salt-and-Pepper Noise · Deep Learning · Median Filter

## 1 Introduction

影像降噪是影像處理與電腦視覺領域中的一項重要任務，其主要目的是從受雜訊干擾的影像中恢復出原始乾淨的影像，同時盡可能保留細節與結構資訊。傳統降噪方法，如中值濾波、高斯濾波與低通濾波等，雖然在計算上效率高、實作簡便，但對於不同類型的雜訊（特別是高斯雜訊）常表現不佳。例如，高斯濾波在處理椒鹽雜訊時，容易導致邊緣模糊與細節喪失。隨著深度學習技術的蓬勃發展，越來越多研究將卷積神經網路（CNN）應用於影像復原任務。其中，DnCNN（Denoising Convolutional Neural Network）模型透過深層殘差學習架構，直接預測雜訊殘差，並以端到端方式進行訓練，在去除高斯雜訊與保留影像細節方面展現出優異的表現。本研究以 DnCNN 為基礎，進一步提出訓練策略與損失函數的改良方法，以提升模型在面對多樣雜訊型態（包含高斯、椒鹽與隨機雜訊）時的泛化能力。具體而言，訓練過程中逐步調整各類雜訊的比例，模擬實際應用中可能遇到的複合型雜訊情境；同時，損失函數結合了傳統的均方誤差（MSE）與較具魯棒性的 Charbonnier loss，以平衡收斂穩定性與敏感度。為系統性評估本模型的效能，本研究使用 BSD 資料集 [1] 作為訓練資料，TID2013 資料集 [2] 作為測試資料，並對測試影像人工添加三種不同雜訊進行測試。最終以三項評估指標 PSNR、SSIM、MSE 與三種傳統濾波方法（中值、高斯、低通）進行比較分析，探討 DnCNN 在不同雜訊情境下的優勢與限制。

## 2 Related Work

影像降噪技術可大致分為兩大類：傳統影像處理方法與基於深度學習的方法。傳統方法如中值濾波、高斯濾波與低通濾波在過去被廣泛應用，並具有低計算成本與實作簡便的優點。中值濾波（Median Filter）在處理椒鹽雜訊方面表現良好，而高斯濾波（Gaussian Filter）則常用於抑制高斯雜訊，低通濾波器則適用於去除頻率較高的噪聲。然而，這些方法都缺少泛化能力，在不同的雜訊上效果落差很大。近年來，卷積神經網路（CNN）被廣泛應用於影像去噪任務，顯著提升了降噪效能。其中，DnCNN（Zhang et al., 2017）[3] 是一種代表性模型，透過學習影像中的殘差噪聲以實現影像重建，並利用 Batch Normalization 與 ReLU 提升收斂效率與模型表現。該方法在 Gaussian Noise 中取得優異成果。然而，原始 DnCNN 模型對於非高斯類型的

雜訊（例如椒鹽或隨機雜訊）缺乏針對性調整，可能導致效果下降。此外，後續研究開始針對特定雜訊進行架構優化。例如，(Rafiee et al., 2023) [4] 採用 Selective Convolutional Blocks 來強化模型對椒鹽雜訊的處理能力，而部分研究也引入注意力機制或小波轉換以增強模型對空間與頻率特徵的敏感度。然而，大多數方法仍以單一雜訊類型為訓練目標，缺乏在複合雜訊環境中的廣泛測試與泛化能力評估。因此，本研究聚焦於 DnCNN 於多重雜訊環境下的性能表現，並透過動態雜訊比例策略與混合損失函數的設計來增強其泛化能力，進而彌補現有研究中在複雜雜訊場景處理方面的不足，亦對 DnCNN 與傳統方法進行了系統性比較。

### 3 Methodology

本研究主要針對多種常見影像雜訊情境，評估傳統濾波器與 DnCNN 模型的去噪能力，並設計一套能提升其泛化能力的訓練流程與損失函數。研究方法可分為四個部分：資料準備、模型架構、訓練設計與對照方法。

#### 3.1 資料來源與雜訊設計

訓練資料取自 BSD (Berkeley Segmentation Dataset)，並將影像轉為灰階後，利用多尺度切割與資料增強方式擷取尺寸為  $40 \times 40$  的影像片段作為訓練輸入。測試資料則使用 TID2013 影像品質資料庫，同樣轉換為灰階處理。為模擬真實情境中可能出現的複合雜訊，對每張影像隨機添加以下三類雜訊：

- 高斯雜訊 (Gaussian noise)：服從常態分佈  $N(0, 25)$  的雜訊，將雜訊直接加到原始像素值上，並限制在  $[0, 255]$  範圍內。
- 椒鹽雜訊 (Salt-and-Pepper noise)：以 5% 的機率隨機選擇像素，將其替換為 0 (胡椒) 或 255 (鹽)，替換值由隨機數決定。
- 隨機雜訊 (Random noise)：以 5% 的機率對像素進行處理，將其替換為  $[0, 128]$  範圍內的均勻分佈隨機值。

在訓練過程中，這些雜訊以動態比例隨 epoch 調整，讓模型逐步學習處理多樣化干擾。

#### 3.2 模型架構

本研究所採用的 DnCNN 模型為一種基於殘差學習的卷積神經網路，其設計目的是直接學習影像中的雜訊分布，進而透過輸入影像減去預測雜訊來還原乾淨影像。模型架構首先包含一層輸入卷積層搭配 ReLU 啟動函數，用以提取低階特徵，接著由 15 層重複堆疊的卷積層組成主體，每層皆包含 Batch Normalization 與 ReLU 激活函數，以穩定訓練並加快收斂速度，最後透過一層不含非線性函數的輸出卷積層，預測出與輸入影像對應的雜訊成分。該網路採用殘差學習機制，透過輸出雜訊與原始輸入相減的方式，達成影像的去噪重建。

#### 3.3 訓練策略與損失函數

為提升模型的穩定性與泛化能力，本研究在訓練過程中採用動態雜訊比例策略與混合損失函數兩項設計。動態雜訊比例策略的核心理念是模擬實際環境中逐步變化的干擾條件，訓練初期以高斯雜訊為主，隨著訓練輪數推進，逐漸增加椒鹽雜訊與隨機雜訊的比例，使模型能在各類雜訊條件下均具備良好的適應能力。在損失函數設計方面，本研究同時採用均方誤差 (MSE) 與 Charbonnier Loss 進行加權組合，權重比例為 2:8，旨在兼顧訓練收斂效率與對非高斯型雜訊的魯棒性。訓練過程使用 Adam 優化器，初始學習率設為  $1e-3$ ，訓練總共進行 180 個 epochs，batch size 設為 128，並透過 MultiStepLR 學習率調整策略，在指定 epoch 階段逐步降低學習率，以穩定模型訓練過程。

#### 3.4 對照方法

為全面比較效果，本研究亦實作三種傳統濾波法作為對照組：

- 中值濾波器 (Median Filter)：對於每個像素，從其鄰近的 8 個像素 (不包含自身) 中取出亮度值後進行排序，並選取中位數作為當前像素的輸出值。此方法能有效移除椒鹽雜訊 (salt-and-pepper noise) 中的極端像素值，且在保留影像邊緣與細節方面表現良好。
- 高斯濾波器 (Gaussian Filter)：使用一個預先定義的  $3 \times 3$  高斯核 (類似於  $\sigma \approx 1$  的標準高斯分佈) 對每個像素與其鄰域進行加權平均，距離越遠的像素權重越低。此方法可有效抑制高斯型加性雜訊，但對椒鹽雜訊與邊緣結構保存的效果有限。
- 低通濾波器 (Low-pass Filter)：以簡單的平均方式對像素的 8 個鄰居進行處理 (不包含自己)，即取鄰域像素的算術平均值作為輸出。該方法相當於在空間域中實作低通濾波，能有效去除高頻雜訊，但也可能模糊細節與邊緣。

所有方法均應用於相同測試資料與雜訊設計下，以確保評估結果具有一致性與公平性。

## 4 Experiments

為評估 DnCNN 模型在多種雜訊條件下的去噪表現，本研究以 TID2013 資料集作為測試集，並將所有測試影像轉換為灰階格式進行處理。雜訊類型涵蓋三種常見干擾：高斯雜訊 ( Gaussian Noise )、椒鹽雜訊 ( Salt-and-Pepper Noise ) 與隨機雜訊 ( Random Noise )，每種雜訊均單獨加入影像後再進行降噪處理。降噪方法包含 DnCNN 模型與三種傳統濾波技術：中值濾波器、高斯濾波器與低通濾波器。訓練方面，DnCNN 模型使用 BSD 資料集進行監督式學習訓練，影像經資料增強後被切割為  $40 \times 40$  的灰階 patch。訓練總共進行 180 輪 ( epochs )，並設計動態雜訊比例調整策略，以逐步模擬從單一類型雜訊到複合型混合雜訊的學習過程。雜訊比例隨訓練輪數變化如下：

- 第 1-20 輪：以高斯雜訊為主 ( 比例 0.8 )，輔以少量隨機雜訊 ( 0.2 )，不含椒鹽雜訊。
- 第 21-40 輪：逐漸加入椒鹽雜訊 ( 0.1 )，調整高斯與隨機雜訊至 0.6 與 0.3。
- 第 41-80 輪：椒鹽雜訊比例逐步由 0.05 遞增至 0.25，其餘比例維持在 0.5 ( 高斯 ) 與 0.25 ( 隨機 )。
- 第 81-180 輪：固定以椒鹽雜訊 0.33、隨機雜訊 0.22 與高斯雜訊 0.45 混合，形成複合性雜訊環境。

損失函數方面，採用 MSE 與 Charbonnier loss 加權混合，以兼顧訓練穩定性與對異常值的容忍度。優化器選用 Adam，初始學習率為  $1e-3$ ，並透過階段性學習率衰減策略 ( MultiStepLR ) 進行調整。為量化不同方法的去噪效能，實驗使用三種常見指標：峰值信噪比 ( PSNR )、結構相似度指數 ( SSIM ) 與均方誤差 ( MSE )。所有測試結果皆進行平均值與標準差統計，以全面比較不同方法在各類雜訊下的整體表現與穩定性。

## 5 Results

本研究以三項影像品質指標——MSE ( 均方誤差 )、PSNR ( 峰值信噪比 ) 與 SSIM ( 結構相似度 )——評估 DnCNN 模型與三種傳統濾波方法在不同雜訊類型下的降噪效能。表格一彙整各方法於高斯雜訊、隨機雜訊與椒鹽雜訊下的平均值與標準差，呈現整體表現與穩定性。

Table 1: Denoising performance of different methods under three noise types (mean  $\pm$  std)

Method	Noise Type	MSE	PSNR	SSIM
DnCNN	Gaussian	<b>0.0017 <math>\pm</math> 0.0013</b>	<b>28.59 <math>\pm</math> 2.72</b>	<b>0.8068 <math>\pm</math> 0.0664</b>
	Random	<b>0.0012 <math>\pm</math> 0.0006</b>	<b>29.61 <math>\pm</math> 2.19</b>	0.7847 $\pm$ 0.0836
	Salt	0.0068 $\pm$ 0.0036	22.05 $\pm$ 1.77	0.6406 $\pm$ 0.1115
Gaussian Filter	Gaussian	0.0033 $\pm$ 0.0043	25.94 $\pm$ 2.54	0.6511 $\pm$ 0.0544
	Random	0.0031 $\pm$ 0.0044	26.70 $\pm$ 3.17	0.7525 $\pm$ 0.0708
	Salt	0.0043 $\pm$ 0.0044	24.50 $\pm$ 2.15	0.5931 $\pm$ 0.0554
Low-pass Filter	Gaussian	0.0052 $\pm$ 0.0075	24.25 $\pm$ 2.82	0.5759 $\pm$ 0.0619
	Random	0.0050 $\pm$ 0.0076	24.72 $\pm$ 3.26	0.6712 $\pm$ 0.0862
	Salt	0.0061 $\pm$ 0.0076	23.25 $\pm$ 2.50	0.5210 $\pm$ 0.0566
Median Filter	Gaussian	0.0064 $\pm$ 0.0100	23.38 $\pm$ 2.74	0.5167 $\pm$ 0.0606
	Random	0.0052 $\pm$ 0.0116	25.80 $\pm$ 4.14	<b>0.7932 <math>\pm</math> 0.0895</b>
	Salt	<b>0.0051 <math>\pm</math> 0.0119</b>	<b>25.93 <math>\pm</math> 4.10</b>	<b>0.7991 <math>\pm</math> 0.0889</b>

整體而言，DnCNN 在大多數情況下展現出最佳的降噪效能，具備最低的 MSE 與最高的 PSNR，特別是在高斯雜訊與隨機雜訊下，表現明顯優於所有傳統濾波方法，顯示其對加性雜訊的處理具有顯著優勢。然而，在椒鹽雜訊情境中，傳統的中值濾波器仍稍具優勢，其在 PSNR ( 25.93 vs 22.05 ) 與 SSIM ( 0.7991 vs 0.6406 ) 兩項指標上均優於 DnCNN，反映出中值濾波在面對極端像素擾動時的優勢。就 SSIM 而言，DnCNN 在處理高斯與隨機雜訊時表現穩定，但在非連續型的椒鹽雜訊下則出現明顯下滑，顯示模型仍有優化空間。在穩定性方面，透過標準差分析可見，DnCNN 在 Gaussian 與 Random 類型中表現波動較小，顯示模型訓練具有一致性與可靠性，相對地，中值濾波雖在某些場景下效果突出，但其結果變異性相對較高，特別是在面對非椒鹽雜訊時。

## 6 Conclusion

本研究針對影像去噪問題，探討了基於深度學習的 DnCNN 模型在多種雜訊情境下的效能表現，並與傳統濾波方法 ( 中值濾波、高斯濾波、低通濾波 ) 進行系統性比較。透過設計動態雜訊比例訓練策略與混合損

失函數，本研究所訓練之 DnCNN 模型展現出良好的泛化能力，尤其在高斯與隨機雜訊場景中，於 PSNR 與 MSE 指標上皆明顯優於傳統方法。不過，實驗也顯示 DnCNN 在處理椒鹽雜訊時表現相對劣勢，傳統中值濾波器則在此情境中仍維持穩定且優異的去噪效果。此結果說明：深度學習雖具強大特徵學習能力，但在應對極端或非連續型雜訊時，仍可能受限於訓練樣本與模型架構之設計。整體而言，DnCNN 在多數雜訊類型下提供穩定且高效的去噪能力，為影像復原任務提供強大工具。未來研究方向可朝向：

- 結合雜訊識別與自適應濾波機制，動態選擇最適應對策略；
- 將注意力機制（Attention）納入模型；
- 嘗試加入小波轉換，提升對非加性雜訊的辨識能力。

本研究證實深度神經網路在多樣化雜訊環境下具高度潛力，同時也驗證經典方法在特定場景中仍可能有相對優勢，兩者整合將可能是未來發展的方向。

## References

- [1] D. Martin, C. Fowlkes, D. Tal, and J. Malik. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics. In *Proc. 8th Int'l Conf. Computer Vision*, volume 2, pages 416–423, July 2001.
- [2] Nikolay Ponomarenko, Lina Jin, Oleg Ieremeiev, Vladimir Lukin, Karen Egiazarian, Jaakko Astola, Benoit Vozel, Kacem Chehdi, Marco Carli, Federica Battisti, and C.-C. Jay Kuo. Image database tid2013: Peculiarities, results and perspectives. *Signal Processing: Image Communication*, 30:57–77, 2015.
- [3] Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, and Lei Zhang. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.
- [4] Ahmad Ali Rafiee and Mahmoud Farhang. A deep convolutional neural network for salt-and-pepper noise removal using selective convolutional blocks. *Applied Soft Computing*, 145:110535, 2023.